

INTRODUCCIÓN

Bienvenidos al desafío de cierre del curso.

Van a construir un sistema de *Retrieval-Augmented Generation* con *tool calling*: dado un *query* en lenguaje natural emitido por un operador del centro de control, predecir la *tool call* correcta en formato canónico, usando documentación técnica recuperada como contexto.

ENCODER

bge-small-en-v1.5

Genera *embeddings* del query y de los *chunks* del corpus técnico de MASA.

ÍNDICE

FAISS

Búsqueda densa sobre los *embeddings* para recuperar los documentos relevantes.

DECODER

Llama-3.2-1B-Instruct

Genera la *tool call* canónica condicionada al contexto recuperado.

PLATAFORMA

Kaggle

Compiten contra los demás grupos sobre el mismo conjunto de prueba.

RESULTADOS DE APRENDIZAJE

Tras esta actividad, el estudiante será capaz de...

- 01 Diseñar e implementar sistemas de *retrieval* densos basados en *encoders* pre-entrenados.
- 02 Realizar *fine-tuning* de modelos de lenguaje tipo *decoder* para tareas de generación estructurada.
- 03 Construir *pipelines* de RAG que combinan *retrieval* (FAISS) con generación condicionada por contexto recuperado.
- 04 Aplicar técnicas de *data augmentation*, *hybrid search* y *reranking* para mejorar el desempeño.
- 05 Diseñar estrategias de *prompting*, post-procesamiento y normalización de *output* para tareas con formato estricto.

AÑO 2026

La humanidad vuelve al espacio profundo. Sudamérica también.

Hace apenas unos días, la misión **Artemis II** de la NASA sobrevoló la Luna con cuatro astronautas a bordo, marcando el regreso de la humanidad a la órbita lunar después de más de 50 años.

En este contexto, la **Misión Aeroespacial Sudamericana Avanzada (MASA)** —la primera agencia espacial latinoamericana— ha puesto en órbita la estación **Kuntur Station**.

KUNTUR STATION

400 km sobre la Tierra

6 tripulantes en una misión de larga duración. Solos. Cualquier decisión equivocada puede poner en riesgo sus vidas.

SU ROL

Construir el agente inteligente que interprete las consultas del centro de control, recupere la documentación técnica relevante y genere la *tool call* precisa que resuelve la situación. La tripulación de Kuntur Station cuenta con ustedes.

SEIS PERSONAS. UNA ESTACIÓN.

La tripulación de Kuntur Station

COMANDANTE Santiago Reyes	PILOTO Ana Valdivia	ESPECIALISTA 1 Kai Nakamura
ESPECIALISTA 2 Fatima Al-Hassan	INGENIERO Pavel Kozlov	OFICIAL MÉDICO Lucía Mendoza

Cada tripulante es un destinatario válido de la *tool* `send_message` : `commander` , `pilot` , `specialist_1` , `specialist_2` , `engineer` , `medical_officer` , `all_crew` .

Kuntur Station

Cóndorcondor Comando y control El cerebro de la estación.	Quetzalquetzal Laboratorio científico 4 tripulantes · 12 estaciones de trabajo.	Jaguarjaguar Soporte vital y sistemas críticos Redundancia Clase A.
Colibrícolibri Comunicaciones y navegación Antenas de largo alcance.	Vicuñavicuna Almacenamiento y carga Puerto de acoplamiento.	Tucántucan Habitacional 6 cabinas individuales.

DETALLE ORTOGRÁFICO

Los documentos técnicos conservan la grafía en español (Cóndor, Colibrí, Vicuña, Tucán). Las tool calls usan la forma ASCII sin acentos (condor , colibri , vicuna , tucan). Estos nombres provienen de lenguas indígenas y del español; son OOV para modelos entrenados en inglés.

DESCRIPCIÓN DE LA COMPETENCIA

Predecir la **tool call** correcta para cada consulta del operador.

Dada una consulta en inglés del centro de control, su sistema debe recuperar los documentos relevantes y generar la *tool call* canónica que resuelve la situación.

CONSULTA DE EJEMPLO

"Oxygen levels in Jaguar dropped to 18.2% over the last hour and pressure is falling. What protocol should we activate?"

LO QUE DEBE HACER SU SISTEMA

1. Recuperar el protocolo MASA-SEC correcto del corpus técnico.
2. Inferir severidad y *scope* desde el documento.
3. Emitir la *tool call* canónica exacta, carácter por carácter.


Salida esperada

```
activate_protocol(protocol_id='MASA-SEC-007',scope='station_wide')
```

Métrica: *Categorization Accuracy* con *exact string match*. Sin crédito parcial.

PIPELINE DE REFERENCIA

RAG + tool calling



ESPACIO DE ACCIONES CERRADO

10 tools, todos los parámetros son enums.

No hay texto libre. Cada parámetro toma un valor de un conjunto cerrado y predefinido. El espacio de salida es finito y verificable mediante *exact match*.

TELEMETRÍA · MONITOREO get_telemetry module · metric · timeframe_hours	ESTADO TRIPULACIÓN get_crew_status module · info	ESTADO MÓDULO get_module_status module · system
ALERTA send_alert module · severity · reason	MENSAJERÍA send_message recipient · priority	MANTENIMIENTO schedule_maintenance module · task · priority
PROTOCOLO DE EMERGENCIA activate_protocol protocol_id · scope	CONTROL DE SISTEMAS control_system module · system · action	TRAYECTORIA calculate_trajectory maneuver · urgency
SUMINISTROS request_supply category · urgency	FALLBACK no_action Sin parámetros · consultas informativas o históricas	

TABLA 1 · ORDEN DE PARÁMETROS OBLIGATORIO

Definición canónica de las 10 tools

TOOL	PARÁMETRO	TIPO	VALORES VÁLIDOS
get_telemetry	module	str	condor, quetzal, jaguar, colibri, vicuna, tucan
	metric	str	temperature, pressure, oxygen, radiation, humidity, power
	timeframe_hours	int	1, 6, 12, 24
get_crew_status	module	str	condor, quetzal, jaguar, colibri, vicuna, tucan
	info	str	health, location, current_activity, schedule
get_module_status	module	str	condor, quetzal, jaguar, colibri, vicuna, tucan
	system	str	life_support, power, thermal, structural, communications
send_alert	module	str	condor, quetzal, jaguar, colibri, vicuna, tucan
	severity	str	low, medium, high, critical
	reason	str	abnormal_temperature, pressure_drop, oxygen_leak, radiation_spike, system_failure, power_fluctuation, communication_loss, structural_damage
send_message	recipient	str	commander, pilot, specialist_1, specialist_2, engineer, medical_officer, all_crew
	priority	str	low, medium, high, urgent
schedule_maintenance	module	str	condor, quetzal, jaguar, colibri, vicuna, tucan
	task	str	sensor_repair, filter_replacement, system_calibration, hull_inspection, power_cell_swap, software_update

REGLAS DE FORMATO — SIN EXCEPCIONES

El **exact match** manda.

La predicción debe coincidir **carácter por carácter** con la *tool call* canónica. No hay crédito parcial. Se permite post-procesamiento (regex, normalización).

- 01 Orden de parámetros según Tabla 1 y `tools_definition.json`. **Orden incorrecto = 0 puntos.**
- 02 Sin espacios después de comas ni antes/después del signo `=`.
- 03 Comillas simples para valores tipo `str`.
- 04 Todo en minúsculas, **excepto** `protocol_id` que va en MAYÚSCULAS (e.g., `MASA-SEC-001`).
- 05 Valores `int` sin comillas — `timeframe_hours=1`, no `timeframe_hours='1'`.

Plantilla canónica

```
tool_name(param_1='value',param_2=42)
```

ATENCIÓN

Aunque los **valores** sean correctos, si el **orden** de los parámetros no coincide con la definición de la *tool*, la predicción se evalúa como **incorrecta**.

ONCE EJEMPLOS VÁLIDOS · UNO INVÁLIDO

Cómo se ve una **tool call** bien formada.

VÁLIDOS

```
get_telemetry(module='tucan',metric='radiation',timeframe_hours=24)
get_crew_status(module='tucan',info='health')
get_module_status(module='tucan',system='life_support')
send_alert(module='vicuna',severity='critical',reason='radiation_spike')
send_message(recipient='all_crew',priority='low')
schedule_maintenance(module='quetzal',task='sensor_repair',priority='routine')
activate_protocol(protocol_id='MASA-SEC-008',scope='module_only')    control_system(module='jaguar',system='heating',action='deactivate')
calculate_trajectory(manuever='reentry',urgency='planned')    request_supply(category='scientific',urgency='emergency')    no_action
```

INVÁLIDO — ORDEN INCORRECTO

```
send_alert(severity='critical',module='quetzal',reason='abnormal_temperature')
```

POR QUÉ FALLA

Aunque los valores son correctos, `severity` aparece antes de `module`. La definición de `send_alert` exige `module` → `severity` → `reason`. **Predicción evaluada como incorrecta.**

VERSIÓN CORRECTA

```
send_alert(module='quetzal',severity='critical',reason='abnormal_temperature')
```

REGLAS NO NEGOCIABLES

Si no se cumplen, la nota del proyecto es 0.

OBLIGATORIO

- ✓ **Decoder:** `meta-llama/Llama-3.2-1B-Instruct` . No se permite otro decoder.
- ✓ **Encoder:** `BAAI/bge-small-en-v1.5` . No se permite otro encoder.
- ✓ *Fine-tuning* del decoder es obligatorio — no basta con *prompt engineering*.
- ✓ El entrenamiento debe realizarse en **PyTorch**.
- ✓ Resultados **replicables** a partir de los entregables en Coursera, partiendo del `train.csv` original.

PROHIBIDO

- ✗ Modelos pagos (OpenAI, Claude, Cohere, Gemini APIs u otros servicios de pago).
- ✗ Datos externos no entregados por el equipo docente.
- ✗ Usar los datos de prueba para entrenar (*data leakage*).
- ✗ Reemplazar el LLM por otra red neuronal de clasificación.

DATA AUGMENTATION PERMITIDO

Pueden generar datos sintéticos con LLMs *open-source* de Hugging Face (descargados localmente) o vía el endpoint gratuito de **NVIDIA Build**. Justificar la elección del modelo en el notebook entregado.

LO QUE RECIBEN PARA CONSTRUIR EL SISTEMA

Descripción de los datos

2 718

train.csv

Consultas de operadores con su `tool_call` correcta. **Contiene ruido** — limpiarlo es parte del reto. Columnas: `id` · `query` · `tool_call` .

766

test.csv

Consultas sin respuesta. Sin superposición con `train.csv` . Columnas: `id` · `query` . Sus predicciones se evalúan en Kaggle.

810

consultas_centro_control.json

Pares (`query`, `doc_id`) históricos. Algunos incluyen `hard_negative_doc_id` . Útil para *fine-tuning* del encoder.

54

base_conocimiento/

Documentos técnicos MASA en Markdown — manuales de módulos, protocolos de seguridad, procedimientos operacionales, guías de sistemas. *Corpus* de retrieval.

10

tools_definition.json

Definición procesable de las 10 *tools*, con todos los parámetros válidos por enumeración. Misma información que la Tabla 1.

CSV

sample_submission.csv

Ejemplo del formato de entrega esperado. Una fila por `id` de `test.csv` con un *placeholder* que deben reemplazar con su predicción.

EJEMPLO DE ENTRADA EN CONSULTAS_CENTRO_CONTROL.JSON

```
{"query": "Which protocol governs radiation lockdown procedures?", "doc_id": "MASA-DOC-009", "hard_negative_doc_id": "MASA-DOC-012"}
```

SUBMISSION A KAGGLE

Cómo se ve un **submission** bien formado.

Un CSV con **una fila por cada id** de `test.csv`. La columna `tool_call` contiene la predicción de su modelo en formato canónico. La métrica es *Categorization Accuracy* con *exact string match*.

submission.csv

```
id,tool_call
T-00001,activate_protocol(protocol_id='MASA-SEC-009',scope='module_only')
T-00002,no_action
T-00003,get_telemetry(module='jaguar',metric='oxygen',timeframe_hours=12)
T-00004,send_alert(module='quetzal',severity='high',reason='pressure_drop')
T-00005,send_message(recipient='commander',priority='urgent')
...
```

MÉTRICA

Categorization Accuracy

Exact string match. La predicción debe coincidir **carácter por carácter** con la *tool call* canónica correcta. **Sin crédito parcial.**

SCORE EN KAGGLE

Score **público** visible durante la competencia (sobre una porción del test).
Score **privado** revelado al cierre (sobre el resto). El privado es el que cuenta.

ANTES DE EMPEZAR A ENTRENAR

Regístrense en Kaggle con el nombre exacto.

- 01 Cada miembro del grupo debe tener cuenta en **kaggle.com**.
- 02 Acepten la invitación a la competencia con el enlace que se compartirá en Coursera.
- 03 Creen un equipo en Kaggle con el nombre **exacto** `Grupo_N`, donde `N` es el número de su grupo asignado en Coursera.
- 04 Únanse todos los integrantes al mismo equipo en Kaggle antes de la primera *submission*.
- 05 Realicen un *submission* de prueba con `sample_submission.csv` para validar el formato.

CRÍTICO

El nombre del equipo es el **identificador** que asocia los resultados de Kaggle con la nota del grupo en Coursera. Si lo escriben mal, no se puede asociar la calificación.

Formato del nombre de equipo

`Grupo_N`

EJEMPLOS VÁLIDOS

`Grupo_1 · Grupo_2 · Grupo_10 · Grupo_15`

EJEMPLOS INVÁLIDOS

`grupo_1 · Grupo 1 · GRUPO_1 · Equipo_1`

Mínimo **5 envíos diferentes** en Kaggle para que la participación sea considerada (20% de la nota). No hay límite máximo. Tienen 2 semanas.

CÓMO SE COMPONE LA NOTA

Rúbrica de evaluación

ITEM 1

20%

Participación en la competencia

Mínimo **5 envíos diferentes** en Kaggle a lo largo de las 2 semanas. La idea es evidenciar iteración sobre el enfoque inicial.

ITEM 2

40%

Superar la línea base

Hay una línea base publicada en el *leaderboard* de Kaggle que deben superar. **Si no la superan, este 40% es 0.**

ITEM 3

40%

Percentil en la competencia

Según el desempeño final en la tabla de líderes. La distribución se detalla en la siguiente diapositiva.

LECTURA HONESTA

Para sacar buena nota: **(1)** hagan ≥ 5 envíos a lo largo de las 2 semanas, **(2)** superen la línea base — sin esto, pierden 40% sí o sí, y **(3)** empujen para entrar al top 25% del *leaderboard*.

EL 40% SEGÚN DESEMPEÑO RELATIVO

Percentil obtenido en la competencia.

Al cerrar la competencia se generan los puntajes finales. Su nota en este rubro depende del percentil obtenido en la tabla de líderes **privada**.

DESEMPEÑO OBTENIDO	PORCENTAJE DEL RUBRO (DE ESE 40%)
< percentil 25	0%
≥ percentil 25 y < percentil 50	50%
≥ percentil 50 y < percentil 75	75%
> percentil 75	100%

INTERPRETACIÓN RÁPIDA

Si quedan en el **top 25%** de la competencia, sacan el 100% de este rubro (es decir, los 40 puntos completos). Si quedan en el **último cuartil**, esos 40 puntos son 0.

SEMANA 8 · COURSERA

Estructura del entrega_grupo_XX.zip

Empaqueten todo en un único `.zip` nombrado `entrega_grupo_XX.zip` (donde `XX` es el número de su grupo en Coursera) y suban un enlace de Google Drive con permisos de lectura para cualquiera con el enlace.

```
entrega_grupo_XX.zip/
  pipeline.ipynb           # Notebook principal
  scripts/                 # Scripts externos (si aplica)
    chunker.py
    finetune_decoder.py
    utils.py
  prompts/                 # Prompts utilizados (si aplica)
    system_prompt.yaml
  models/
    decoder/               # Llama-3.2-1B fine-tuneado
      adapter_config.json
      adapter_model.safetensors
      tokenizer.json
      ...
    encoder/               # bge-small-en-v1.5 fine-tuneado (si aplica)
      config.json
      model.safetensors
      tokenizer.json
      ...
  retrieval_index.json      # Indice con chunks y vectores
  requirements.txt          # Dependencias
```

retrieval_index.json — formato esperado

```
[
  {
    "doc_id": "MASA-DOC-007",
    "chunk_id": 0,
    "text": "...",
    "vector": [0.123, -0.456, ...]
  },
  ...
]
```

REGLAS

Si un documento se divide en múltiples *chunks*, el `doc_id` se repite y cada `chunk_id` es único, tanto dentro de ese documento como de forma global. La estructura del notebook se detalla en el siguiente slide.

Estructura del **notebook** principal

El notebook debe ser **autocontenido**: ejecutar de inicio a fin reproduce todo el *pipeline* — desde la carga de datos hasta la generación del *submission*. Toda *data augmentation* debe quedar documentada en el mismo notebook.

```
# 1. Carga y Exploración de Datos
- Carga de train.csv, consultas_centro_control.json, documentos MASA
- Análisis exploratorio: distribución de tools, estadísticas

# 2. Preprocesamiento
- Limpieza de datos (ruido)
- Chunking de documentos
- Generación de datos adicionales (si aplica, justificar modelo usado)

# 3. Entrenamiento
- Fine-tuning del encoder (si aplica)
- Construcción del índice FAISS
- Fine-tuning del decoder (obligatorio)

# 4. Inferencia
- Carga de modelos entrenados
- Pipeline completo: query → retrieval → generación → post-procesamiento

# 5. Generación del Archivo de Respuesta
- Generación de submission.csv para Kaggle
```

ATENCIÓN

Un notebook que **no sea ejecutable de forma autónoma** o que dependa de rutas absolutas externas recibe penalización de **−1.0 unidad**. Si usan *scripts* de

LÉANLAS CON CALMA

Penalizaciones sobre la nota final del proyecto.

-1.0

Estructura del .zip incorrecta

El `.zip` debe respetar exactamente la estructura de carpetas descrita. Entregas que no la sigan reciben **-1.0 unidad**.

-1.0

Notebook no autocontenido

El notebook debe ejecutar de inicio a fin sin rutas absolutas externas y reproducir todo el *pipeline*. Si no es ejecutable o verificable, no se puede evaluar.

-0.3

Nombre de archivo incorrecto

Debe llamarse exactamente `entrega_grupo_XX.zip`. Otro nombre = penalización de **-0.3 unidades**.

CÓMO EVITARLAS

Antes de entregar: **(1)** validen el nombre del archivo, **(2)** verifiquen la estructura de carpetas contra esta presentación, y **(3)** ejecuten el notebook de cero en una sesión limpia para confirmar que reproduce el pipeline completo.

CALENDARIO DE LA COMPETENCIA

Tienen **dos semanas**
para construirlo todo.

APERTURA

10/05/2026

11:59 PM UTC-5

La competencia abre en Kaggle. A partir de este momento pueden enviar predicciones.

CIERRE

24/05/2026

11:59 PM UTC-5

Última fecha para enviar a Kaggle. Después se revela el score privado y se calculan los percentiles.

RECOMENDACIÓN DE CRONOGRAMA

Semana 1: limpieza de datos, baseline replicado, primer fine-tuning del decoder, primeras submissions.

Semana 2: fine-tuning del encoder, hard negatives, data augmentation, post-procesamiento, iteraciones para subir en el leaderboard.

ANTES DE CERRAR

Lo que separa una **baseline** de una solución competitiva.

Ejes de exploración

- **Analizar los datos** que tienen — entender la distribución de *tools*, parámetros y casos límite antes de modelar.
- **Revisar las consultas** — qué información está en el *query*, qué información hay que recuperar del corpus.
- **Estrategias de chunking** — tamaño, solapamiento, granularidad por tipo de documento.
- **Funciones de pérdida** para retrieval — la elección de *loss* es lo que más mueve la aguja del encoder.
- **Aumentación de datos** — pensar qué datos sintéticos pueden generar para fortalecer el entrenamiento.

LO MÁS IMPORTANTE

Lean el estado del arte. Papers recientes y documentación técnica de las librerías son la diferencia entre apenas superar la línea base y alcanzar un desempeño competitivo. Ahí está lo mejor que pueden hacer.

BUENA SUERTE, EQUIPOS

La tripulación de Kuntur Station cuenta con ustedes.

Volver al índice ↩